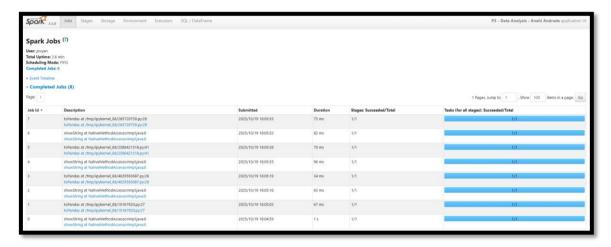
Nombre: Anahí Andrade Fecha: 19-10-2025

Código: 00323313

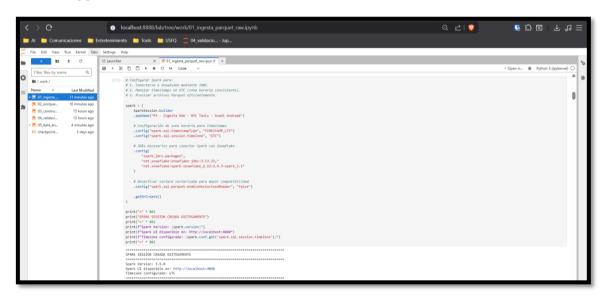
Data Mining - Deber 3

1. Evidencia - Capturas de Spark ejecutándose en el puerto designado, al igual que Servidor Jupyter:

Puerto (http://localhost:4040):



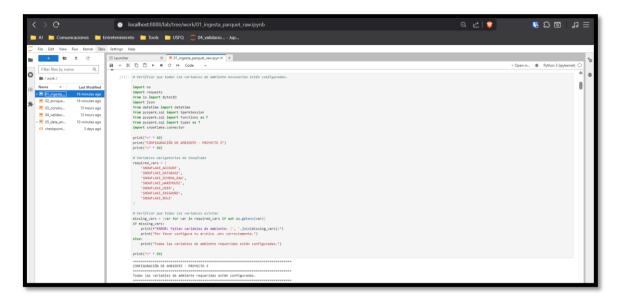
Servidor Jupyter:



2. Evidencia – Docker Compose ejecutándose:



3. Evidencia - Variables de ambiente bien usadas:



4. Evidencia - Cobertura real 2015-2025 (Yellow/Green):

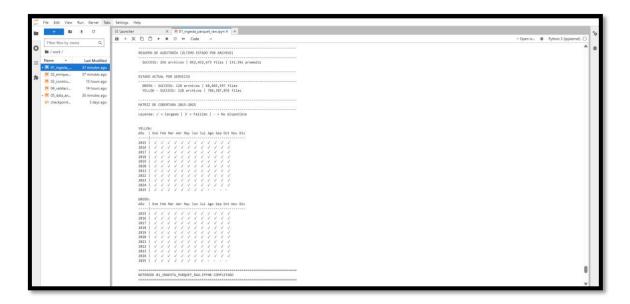
Tabla INGESTA AUDIT:

Se creó en Snowflake una tabla de auditoría llamada INGESTA_AUDIT dentro del esquema RAW. Esta tabla registra información como el tipo de servicio del archivo Parquet (YELLOW/GREEN), el año y mes correspondientes, la URL del archivo, el número de lote, la cantidad de filas contenidas, el tiempo de ejecución, el estado del proceso (exitoso o fallido), entre otros datos. Su propósito fue facilitar la identificación de los años y meses que se procesaron correctamente.



Jupiter:

De forma similar, en el notebook **01_ingesta_parquet_raw.ipynb** se incluyeron impresiones de auditoría.



5. Evidencia – Datos y Metadatos de la cobertura real 2015–2025 (Yellow/Green): Tabla RAW YELLOW TRIPS:

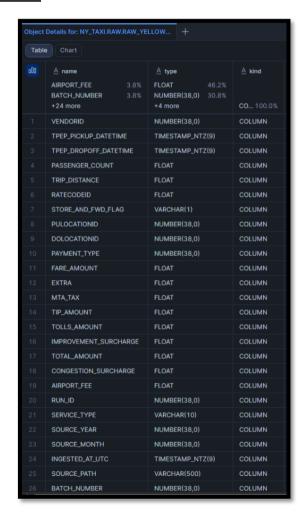
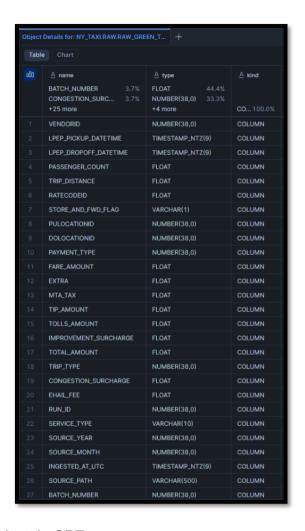
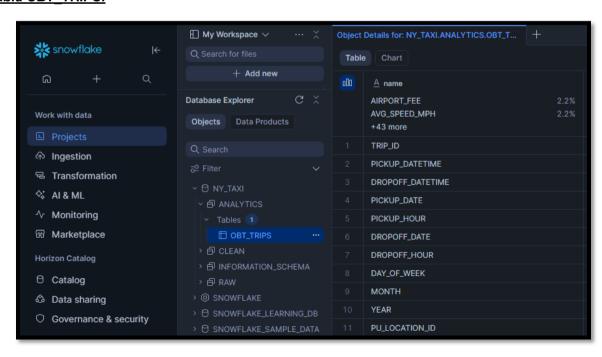


Tabla RAW GREEN TRIPS:



6. Evidencia - Snapshot de OBT:

Tabla OBT TRIPS:



A name AIRPORT_FEE AVG SPEED MPH	2.2%	<u>A</u> type FLOAT 33.3% NUMBE 28.9%	A kind
+43 more		+7 more	
TRIP_ID		VARCHAR(64)	COLUMN
PICKUP_DATETIME		TIMESTAMP_NTZ(9	COLUMN
DROPOFF_DATETIME		TIMESTAMP_NTZ(9	COLUMN
PICKUP_DATE		DATE	COLUMN
PICKUP_HOUR		NUMBER(38,0)	COLUMN
DROPOFF_DATE		DATE	COLUMN
DROPOFF_HOUR		NUMBER(38,0)	COLUMN
DAY_OF_WEEK		NUMBER(38,0)	COLUMN
MONTH		NUMBER(38,0)	COLUMN
YEAR		NUMBER(38,0)	COLUMN
PU_LOCATION_ID		NUMBER(38,0)	COLUMN
PU_ZONE		VARCHAR(100)	COLUMN
PU_BOROUGH		VARCHAR(50)	COLUMN
DO_LOCATION_ID		NUMBER(38,0)	COLUMN
DO_ZONE		VARCHAR(100)	COLUMN
DO_BOROUGH		VARCHAR(50)	COLUMN
SERVICE_TYPE		VARCHAR(10)	COLUMN
VENDOR_ID		NUMBER(38,0)	COLUMN
VENDOR_NAME		VARCHAR(100)	COLUMN
RATE_CODE_ID		FLOAT	COLUMN
RATE_CODE_DESC		VARCHAR(50)	COLUMN
PAYMENT_TYPE		NUMBER(38,0)	COLUMN
PAYMENT_TYPE_DESC		VARCHAR(50)	COLUMN
TRIP_TYPE		NUMBER(38,0)	COLUMN

000	A name	A type	A kind
	AIRPORT_FEE 2. AVG_SPEED_MPH 2.	FLOAT 33.3% NUMBE 28.9%	
~~	+43 more	+7 more	CO 100.0%
21	RATE_CODE_DESC	VARCHAR(50)	COLUMN
22	PAYMENT_TYPE	NUMBER(38,0)	COLUMN
23	PAYMENT_TYPE_DESC	VARCHAR(50)	COLUMN
24	TRIP_TYPE	NUMBER(38,0)	COLUMN
25	TRIP_TYPE_DESC	VARCHAR(50)	COLUMN
26	PASSENGER_COUNT	FLOAT	COLUMN
27	TRIP_DISTANCE	FLOAT	COLUMN
28	STORE_AND_FWD_FLAG	VARCHAR(1)	COLUMN
29	FARE_AMOUNT	FLOAT	COLUMN
30	EXTRA	FLOAT	COLUMN
31	MTA_TAX	FLOAT	COLUMN
32	TIP_AMOUNT	FLOAT	COLUMN
33	TOLLS_AMOUNT	FLOAT	COLUMN
34	IMPROVEMENT_SURCHARGE	FLOAT	COLUMN
35	CONGESTION_SURCHARGE	FLOAT	COLUMN
36	AIRPORT_FEE	FLOAT	COLUMN
37	TOTAL_AMOUNT	FLOAT	COLUMN
38	TRIP_DURATION_MIN	FLOAT	COLUMN
39	AVG_SPEED_MPH	FLOAT	COLUMN
40	TIP_PCT	FLOAT	COLUMN
41	RUN_ID	NUMBER(38,0)	COLUMN
42	INGESTED_AT_UTC	TIMESTAMP_NTZ(9	COLUMN
43	SOURCE_SERVICE	VARCHAR(10)	COLUMN
44	SOURCE_YEAR	NUMBER(38,0)	COLUMN
45	SOURCE_MONTH	NUMBER(38,0)	COLUMN